

Tarea Optimización

Kelen Alfaro García

November 2025

1 Modelo a analizar:

$$f(x, y) = \sin(x + y) + \frac{(x + y)^2 + (x - y)^2}{6}$$

2 Análisis del modelo:

$$D = \{(x, y) \in \mathbb{R}^2 \mid -100 \leq x \leq 100, -100 \leq y \leq 100\}$$

La función es continua y derivable en todo $\mathbb{R}^2$, ya que es combinación de funciones continuas (seno y polinomios). Por tanto:

$$f \in C^\infty(\mathbb{R}^2)$$

y es una función diferenciable en todo su dominio.

Derivadas parciales:

$$\frac{\partial f}{\partial x} = \cos(x + y) + \frac{2x}{3} \quad (1)$$

$$\frac{\partial f}{\partial y} = \cos(x + y) + \frac{2y}{3} \quad (2)$$

Gradiente:

$$\nabla f(x, y) = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix} = \begin{pmatrix} \cos(x + y) + \frac{2x}{3} \\ \cos(x + y) + \frac{2y}{3} \end{pmatrix} \quad (3)$$

Los puntos estacionarios se obtienen resolviendo:

$$\nabla f(x, y) = 0 \implies \begin{cases} \cos(x + y) + \frac{2x}{3} = 0, \\ \cos(x + y) + \frac{2y}{3} = 0. \end{cases}$$

Restando las ecuaciones se obtiene $x = y$. Sustituyendo en la primera ecuación:

$$\cos(2x) + \frac{2x}{3} = 0.$$

Esta ecuación no tiene solución analítica cerrada, por lo que los valores x^* se obtienen numéricamente. Sea x^* una raíz de la ecuación anterior, entonces:

$$(x^*, y^*) = (x^*, x^*)$$

es un punto estacionario de f .

Hessiana:

$$H_f(x, y) = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix} = \begin{pmatrix} -\sin(x+y) + \frac{2}{3} & -\sin(x+y) \\ -\sin(x+y) & -\sin(x+y) + \frac{2}{3} \end{pmatrix} \quad (4)$$

El determinante y la traza del Hessiano son:

$$\det(H) = (-\sin(x+y) + \frac{2}{3})^2 - (-\sin(x+y))^2 = \frac{4}{9} - \frac{4}{3} \sin(x+y),$$

$$\text{tr}(H) = 2(-\sin(x+y) + \frac{2}{3}).$$

Los valores propios del Hessiano se obtienen resolviendo:

$$\det(H - \lambda I) = 0,$$

lo que da:

$$\lambda_{1,2} = -\sin(x+y) + \frac{2}{3} \pm (-\sin(x+y)).$$

Simplificando:

$$\lambda_1 = \frac{2}{3}, \quad \lambda_2 = \frac{2}{3} - 2\sin(x+y).$$

Convexidad global: El término cuadrático $(x+y)^2 + (x-y)^2$ es estrictamente convexo, pero el seno introduce oscilaciones periódicas que hacen que la función no sea globalmente convexa.

Por tanto, $f(x, y)$ es no convexa globalmente, pero puede tener regiones localmente convexas dependiendo del signo de $\sin(x+y)$.

Existencia de soluciones y óptimos:

- La función es continua en $\mathbb{R}^2 \Rightarrow$ existe al menos un mínimo local.
- No existe mínimo local único, ya que la función tiene un componente periódico $\sin(x+y)$ que genera infinitos mínimos y máximos locales.
- El término cuadrático crece sin límite cuando $x, y \rightarrow \infty$, lo que implica que sí existe un mínimo global, ya que $f(x, y) \rightarrow \infty$ conforme $\|(x, y)\| \rightarrow \infty$.
- Por tanto, la función posee al menos un mínimo global absoluto y una cantidad infinita de mínimos locales.

3 Algoritmos a utilizar:

Dos algoritmos computacionales serán utilizados para hallar el punto mínimo global de la función, estos serán el método del gradiente descendiente con y sin backtracking y el método de Newton con damping.

- El descenso de Gradiente es un método comúnmente utilizado en problemas de optimización. Es como intentar encontrar el punto más bajo en un paisaje montañoso. Se comienza en un punto al azar y se dan pasos pequeños en dirección contraria al gradiente, que es la dirección del descenso más empinado. La función objetivo se minimiza mediante el cálculo del siguiente punto, utilizando el gradiente del punto actual, escalando con una razón de aprendizaje. La convergencia del algoritmo depende de la elección de la tasa de aprendizaje y el número de iteraciones.

- El método de Newton es un algoritmo iterativo para encontrar mínimos (o máximos) de funciones diferenciables usando información de primera y segunda derivada. A diferencia del gradiente descendente, Newton utiliza la matriz Hessiana para determinar la dirección y el tamaño del paso óptimo.

4 Conclusiones:

En los experimentos realizados, se observa una clara diferencia en el comportamiento del gradiente descendente (GD) y del método de Newton con damping al optimizar la función. Según se puede observar en la tabla resumen, los experimentos con GD desde diferentes puntos iniciales $(0,0)$, $(2,-1)$ y $(-2,2)$ convergen todos a punto cercano a $(-0.586506, -0.586506)$ con un valor final de la función aproximado a -0.6926 . La norma del gradiente es muy pequeña (10^{-7}), lo que indica que se alcanzó un mínimo local estable. Sin embargo, GD requirió 23 a 53 iteraciones para llegar a estos resultados, mostrando un descenso relativamente gradual y sensible al tamaño del paso inicial y al uso de backtracking.

Por su parte, Newton con damping también converge al mismo mínimo cercano al origen cuando se inicia desde $(0,0)$, pero lo logra en solo 5 iteraciones, con una norma del gradiente extremadamente pequeña (10^{-11}), reflejando la convergencia cuadrática característica del método y su capacidad de aprovechar la curvatura de la función. Esto evidencia que Newton puede alcanzar el mínimo global de manera mucho más rápida y eficiente que GD cuando se encuentra relativamente cerca del valle parabólico. Es interesante notar que cuando Newton se inicia desde un punto lejano como $(3,3)$ el método converge a un mínimo diferente alrededor de $(0.5847, 0.5847)$ con un valor en la función aproximado a 1.148 , alcanza el máximo número de iteraciones permitido (500). Esto resalta que Newton, aunque muy eficiente cerca de un mínimo, encuentra el mínimo más cercano al punto inicial, y el damping evita que diverja en regiones alejadas, pero no garantiza alcanzar el mínimo global desde cualquier posición inicial.

En términos de trayectorias y eficiencia:

El gradiente descendente tiene: pasos pequeños, descenso gradual, sensible al paso inicial y al backtracking, puede requerir muchas iteraciones, pero encuentra

consistentemente un mínimo local cercano al punto inicial.

Y, Newton con damping: pasos más precisos y directos, muy pocas iteraciones cerca del mínimo, converge rápidamente y con gran estabilidad, pero el resultado final depende fuertemente del punto inicial, especialmente en regiones donde la función tiene múltiples mínimos.

En resumen, la comparación muestra que ambos métodos son capaces de encontrar mínimos locales, pero Newton es significativamente más rápido y eficiente cuando se encuentra en la vecindad de un mínimo, mientras que GD ofrece un comportamiento más predecible y gradual desde cualquier punto inicial. El mínimo global alcanzado en la mayoría de los experimentos cercanos al origen corresponde aproximadamente a $(-0.586506, -0.586506)$ con un valor final de la función aproximado a -0.6926 .