

Tarea Optimización

Kelen Alfaro García

November 2025

Repositorio en GitHub

1. Modelo a analizar:

$$f(x, y) = \sin(x + y) + \frac{(x + y)^2 + (x - y)^2}{6}$$

2. Análisis del modelo:

$$D = \{(x, y) \in \mathbb{R}^2 \mid -100 \leq x \leq 100, -100 \leq y \leq 100\}$$

La función es continua y derivable en todo $\mathbb{R}^2$, ya que es combinación de funciones continuas (seno y polinomios). Por tanto:

$$f \in C^\infty(\mathbb{R}^2)$$

y es una función diferenciable en todo su dominio.

Derivadas parciales:

$$\frac{\partial f}{\partial x} = \cos(x + y) + \frac{2x}{3} \quad (1)$$

$$\frac{\partial f}{\partial y} = \cos(x + y) + \frac{2y}{3} \quad (2)$$

Gradiente:

$$\nabla f(x, y) = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix} = \begin{pmatrix} \cos(x + y) + \frac{2x}{3} \\ \cos(x + y) + \frac{2y}{3} \end{pmatrix} \quad (3)$$

Los puntos estacionarios se obtienen resolviendo:

$$\nabla f(x, y) = 0 \implies \begin{cases} \cos(x + y) + \frac{2x}{3} = 0, \\ \cos(x + y) + \frac{2y}{3} = 0. \end{cases}$$

Restando las ecuaciones se obtiene $x = y$. Sustituyendo en la primera ecuación:

$$\cos(2x) + \frac{2x}{3} = 0.$$

Esta ecuación no tiene solución analítica cerrada, por lo que los valores x^* se obtienen numéricamente. Sea x^* una raíz de la ecuación anterior, entonces:

$$(x^*, y^*) = (x^*, x^*)$$

es un punto estacionario de f .

Puntos estacionarios y su clasificación:

Pasando a las variables $s = x + y$ y $t = x - y$ se tiene

$$f(s, t) = \sin(s) + \frac{s^2 + t^2}{6},$$

de modo que los puntos críticos satisfacen $t = 0$ y

$$\cos(s) + \frac{s}{3} = 0.$$

La ecuación anterior presenta exactamente tres raíces reales (resueltas numéricamente):

$$s_1 \approx -1,17012095, \quad s_2 \approx 2,66317888, \quad s_3 \approx 2,93810039,$$

y los puntos críticos en (x, y) son $P_i = (s_i/2, s_i/2)$, $i = 1, 2, 3$. Evaluando la Hessiana en (s, t) se obtiene $f_{ss} = -\sin(s) + \frac{1}{3}$ y $f_{tt} = \frac{1}{3}$; por tanto:

- $P_1 \approx (-0,58506048, -0,58506048)$: $f(P_1) \approx -0,6926006069$, $f_{ss} > 0$, $f_{tt} > 0 \Rightarrow$ **mínimo local** (y, al comparar valores, **mínimo global**).
- $P_2 \approx (1,33158944, 1,33158944)$: $f(P_2) \approx 1,6424585782$, $f_{ss} < 0 \Rightarrow$ **punto de silla** (no mínimo).
- $P_3 \approx (1,46905020, 1,46905020)$: $f(P_3) \approx 1,6408297468$, $f_{ss} > 0$, $f_{tt} > 0 \Rightarrow$ **mínimo local**.

Dado que $f(s, t) \rightarrow +\infty$ cuando $\|(s, t)\| \rightarrow \infty$, existe al menos un mínimo global; comparando los valores de f en los puntos críticos se concluye que P_1 es el **mínimo global absoluto** con $f(P_1) \approx -0,6926006069$.

Hessiana:

$$H_f(x, y) = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix} = \begin{pmatrix} -\sin(x+y) + \frac{2}{3} & -\sin(x+y) \\ -\sin(x+y) & -\sin(x+y) + \frac{2}{3} \end{pmatrix} \quad (4)$$

El determinante y la traza del Hessiano son:

$$\det(H) = (-\sin(x+y) + \frac{2}{3})^2 - (-\sin(x+y))^2 = \frac{4}{9} - \frac{4}{3} \sin(x+y),$$

$$\text{tr}(H) = 2 \left(-\sin(x+y) + \frac{2}{3} \right).$$

Los valores propios del Hessiano se obtienen resolviendo:

$$\det(H - \lambda I) = 0,$$

lo que da:

$$\lambda_{1,2} = -\sin(x+y) + \frac{2}{3} \pm (-\sin(x+y)).$$

Simplificando:

$$\lambda_1 = \frac{2}{3}, \quad \lambda_2 = \frac{2}{3} - 2 \sin(x + y).$$

Como:

$$\Rightarrow \det H = \frac{4}{9}(1 - 3 \sin(x + y)).$$

Por tanto, si $1 - 3 \sin(x + y) \neq 0$, la inversa es

$$H^{-1}(x, y) = \frac{1}{\det H} \begin{pmatrix} \frac{2}{3} - a & a \\ a & \frac{2}{3} - a \end{pmatrix} = \frac{9}{4(1 - 3a)} \begin{pmatrix} \frac{2}{3} - a & a \\ a & \frac{2}{3} - a \end{pmatrix}, \quad a = \sin(x + y).$$

Convexidad global: El término cuadrático $(x + y)^2 + (x - y)^2$ es estrictamente convexo, pero el seno introduce oscilaciones periódicas que hacen que la función no sea globalmente convexa.

Por tanto, $f(x, y)$ es no convexa globalmente, pero puede tener regiones localmente convexas dependiendo del signo de $\sin(x + y)$.

Existencia de soluciones y óptimos:

- La función posee una cantidad finita y pequeña de mínimos locales. A pesar del componente periódico del seno, el término cuadrático domina el crecimiento, capturando solo dos mínimos locales dentro de la cuenca principal de la función, siendo uno de ellos el mínimo global ($f \approx -0.69$). La función tiene tres puntos estacionarios, el mínimo global, un mínimo local y un punto silla
- Existencia del Mínimo Global: Garantizada. La función es una suma de un término acotado ($\sin(x + y)$, entre -1 y 1) y un término cuadrático que crece sin límite, $\frac{1}{3}(x^2 + y^2)$. Esta propiedad, conocida como coercividad, asegura por el Teorema de Weierstrass que la función alcanza un mínimo absoluto en algún punto de $\mathbb{R}^2$.

3. Algoritmos a utilizar:

Dos algoritmos computacionales serán utilizados para hallar el punto mínimo global de la función, estos serán el método del gradiente descendiente con y sin backtracking y el método de Newton con damping.

3.1. Método del Descenso del Gradiente:

El descenso de gradiente es un método comúnmente utilizado en problemas de optimización. Es como intentar encontrar el punto más bajo en un paisaje montañoso. Se comienza en un punto al azar y se dan pasos pequeños en dirección contraria al gradiente, que es la dirección del descenso más empinado. La función objetivo se minimiza mediante el cálculo del siguiente punto, utilizando el gradiente del punto actual, escalando con una razón de aprendizaje. La convergencia del algoritmo depende de la elección de la tasa de aprendizaje y el número de iteraciones.

El procedimiento funciona de la siguiente manera: se elige un punto (x_0, y_0) y una tasa de aprendizaje α . Se calcula el gradiente y se van actualizando las variables de la siguiente forma:

$$x_{k+1} = x_k - \alpha \frac{\partial f}{\partial x}(x_k, y_k),$$

$$y_{k+1} = y_k - \alpha \frac{\partial f}{\partial y}(x_k, y_k)$$

El método continúa la iteración hasta llegar a algún criterio de parada:

- $\|\nabla f(x_k, y_k)\| < \text{tolerancia}$
- Número máximo de iteraciones
- Cambio pequeño en $f(x, y)$ entre iteraciones

El método del gradiente descendente con *backtracking* cambia el α en cada iteración (no es fijo). Entonces las variables se actualizan como:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

El α_k se ajusta para cumplir la condición de **Armijo**:

$$f(x_k - \alpha_k \nabla f(x_k)) \leq f(x_k) - c \alpha_k \|\nabla f(x_k)\|^2$$

Si la condición no se cumple, se reduce α_k multiplicando por ρ .

En el método del GD sin backtracking no existe control, ya que el paso no depende de la función, es fijo. Si α es muy grande, el método puede divergir, y si es muy pequeño, el método tendrá una convergencia lenta. Sin embargo, el método sin backtracking es bastante fácil de implementar.

Por otro lado, en la implementación con backtracking el paso es variable, adaptándose a la función, por lo que existe un mayor control. Se asegura que cada iteración reduzca suficientemente la función. El método con el uso de backtracking es más estable y puede converger incluso en funciones con valles estrechos o pendientes muy pronunciadas. Pero como cada iteración requiere evaluar la función varias veces, es más costoso.

La función correspondiente es:

$$f(x, y) = \sin(x + y) + \frac{(x + y)^2 + (x - y)^2}{6}$$

La función es derivable, lo cual es ideal para GD que requiere el uso del gradiente.

La parte cuadrática:

$$\frac{(x + y)^2 + (x - y)^2}{6}$$

- Es convexa, suave y bien condicionada.
- Tiene una forma de “valle parabólico”.
- Para esta parte, el gradiente descendente converge rápido incluso con paso fijo.

La parte del seno:

$$\sin(x + y)$$

- Introduce oscilaciones y posibles mínimos locales.
- GD puede explorar la función gradualmente y descender hacia un mínimo local.

Sin backtracking

- La función es suave y no tiene cambios extremos de curvatura, por lo que un paso razonable puede funcionar.
- Es rápido de implementar, útil para probar mínimos locales.

Con backtracking

- La parte sinusoidal puede producir zonas donde el gradiente es grande o muy pequeño.
- Backtracking ajusta el paso automáticamente, evitando sobrepasar mínimos y mejorando la estabilidad.
- Es especialmente útil para explorar zonas más alejadas del mínimo, donde el gradiente puede cambiar rápidamente.

3.2. El método de Newton:

El método de Newton es un algoritmo iterativo para encontrar mínimos (o máximos) de funciones diferenciables usando información de primera y segunda derivada. A diferencia del gradiente descendente, Newton utiliza la matriz Hessiana para determinar la dirección y el tamaño del paso óptimo.

Para una función $f(x, y)$:

Gradiente

$$\nabla f(x, y) = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix}$$

Hessiana

$$H(x, y) = \begin{pmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{pmatrix}$$

Aproximación cuadrática

$$f(x + \Delta x, y + \Delta y) \approx f(x, y) + \nabla f^T \Delta + \frac{1}{2} \Delta^T H \Delta$$

donde

$$\Delta = \begin{pmatrix} \Delta x \\ \Delta y \end{pmatrix}$$

Actualización clásica

$$H(x_k, y_k) \Delta_k = -\nabla f(x_k, y_k)$$

$$(x_{k+1}, y_{k+1}) = (x_k, y_k) - \Delta_k = (x_k, y_k) - H(x_k, y_k)^{-1} \nabla f(x_k, y_k)$$

Damping (amortiguación) en el método de Newton

Newton puro puede divergir si:

- La Hessiana no es positiva definida.
- Estamos lejos del mínimo.
- La función presenta oscilaciones, como en $\sin(x + y)$.

Para mejorar la estabilidad, se introducen dos mecanismos de damping:

Factor de escala α_k (line search)

Se multiplica la dirección de Newton por un factor $\alpha_k \in (0, 1]$ que se ajusta mediante backtracking:

$$(x_{k+1}, y_{k+1}) = (x_k, y_k) - \alpha_k H(x_k, y_k)^{-1} \nabla f(x_k, y_k)$$

- Cerca del mínimo, $\alpha_k \approx 1$ y el método conserva su convergencia cuadrática.
- Si la dirección de Newton es riesgosa, $\alpha_k < 1$ reduce el paso y evita divergencia.

Regularización de la Hessiana (Levenberg–Marquardt)

Se añade un término λI a la Hessiana para garantizar que sea positiva definida:

$$(H(x_k, y_k) + \lambda I) \Delta_k = \nabla f(x_k, y_k)$$

- $\lambda > 0$ regula la amortiguación:
 - Valores grandes $\rightarrow$ comportamiento similar al gradiente descendente (pasos pequeños y seguros).
 - Valores pequeños $\rightarrow$ comportamiento cercano a Newton puro.
- I es la matriz identidad de tamaño igual a la Hessiana.

Ventajas del damping

- Garantiza descenso seguro de la función en cada iteración.
- Permite que Newton sea robusto frente a oscilaciones o puntos de silla.
- Combina la rapidez de Newton cerca del mínimo con la estabilidad del gradiente descendente en regiones difíciles.

El método de Newton presenta varias ventajas para la función correspondiente. Primero, tiene convergencia rápida en la parte cuadrática, ya que la porción parabólica de la función se aprovecha al máximo, permitiendo que Newton alcance el mínimo local en pocas iteraciones. Además, ofrece un manejo eficiente de la curvatura variable: la parte sinusoidal introduce cambios en la curvatura según la posición, y Newton ajusta la dirección y el tamaño del paso basándose en la Hessiana, tomando decisiones más informadas que el gradiente descendente. Por último, el damping garantiza estabilidad, ya que en zonas alejadas del mínimo o con oscilaciones fuertes, evita que Newton haga saltos excesivos y diverja. Esto hace que el método sea robusto incluso al explorar regiones complicadas de la función.

4. Análisis de los resultados de los algoritmos

Se ejecutó un total de 600 experimentos para comparar el rendimiento del método de Gradiente Descendente (GD) y el Método de Newton en la optimización de tu función objetivo. La función objetivo resultó ser compleja, presentando dos puntos de interés principales. El objetivo era encontrar el mínimo global, cuyo valor es $f \approx -0,6926$ (ubicado en el punto $x \approx [-0,585, -0,585]$). Sin embargo, la función también posee un mínimo local que actúa como una "trampa" (ubicado en $f \approx 1,64$, en el punto $x \approx [1,469, 1,469]$).




Figura 1: Gráfico de la función objetivo con el mínimo global y el mínimo local.

El análisis comparativo entre el método de Gradiente Descendente (GD) y el Método de Newton subraya diferencias cruciales en cuanto a robustez, velocidad de convergencia e influencia de la búsqueda de línea (Line Search) en el rendimiento global.

Robustez y Fiabilidad:

- **GD con backtracking:** Este método demostró una robustez superior. Logró converger sistemáticamente al mínimo global ($f \approx -0,6926$) a pesar de iniciar desde puntos iniciales significativamente alejados (ej. $\mathbf{x}_0 = [-100, -100]$ o $\mathbf{x}_0 = [50, 50]$). Esta fiabilidad lo posiciona como la opción recomendada para escenarios donde el punto inicial es desconocido o incierto.

- **GD sin backtracking:** Es muy poco robusto. Falló en varios casos, específicamente aquellos que comenzaron en el cuadrante positivo (ej. $[50, 50]$), este método falló en encontrar el mínimo global. Convergió exitosamente, pero al mínimo local ($f \approx 1,64$).
- **Newton:** Este método exhibió una sensibilidad extrema a la condición inicial. En puntos de inicio distantes, el algoritmo divergió o se estancó prematuramente (alcanzando el límite de iteraciones con una alta norma del gradiente), lo cual sugiere que la aproximación cuadrática local proporcionada por la matriz Hessiana no fue precisa en regiones lejanas al óptimo. Las versiones con búsqueda lineal se quedaban atascadas y llegaban al máximo de iteraciones sin explorar mucho de la función. Y las versiones sin búsqueda lineal divergían o se quedaban atascadas. En otros casos, como por ejemplo cuando iniciaba cerca del objetivo (ej. $[0, 0]$ o $[5, -5]$) y usaba búsqueda de línea era extremadamente rápido; llega al mínimo global en un rango de 5 a 9 iteraciones.




Figura 2: Gráfico de la tasa de convergencia por método y resultado.

Eficiencia y velocidad de convergencia:

- **GD con backtracking:** Aunque no fue el más rápido, su velocidad de convergencia fue consistente y altamente eficiente (14 a 26 iteraciones) en todas las condiciones probadas. Su rendimiento es óptimo en la relación velocidad-fiabilidad.
- **GD sin backtracking:** Es muy lento en la mayoría de los casos. cuando tenía puntos iniciales "lejos" ($[-100, -100]$) con un lr bajo (0.01) se tardó más de 1000 iteraciones para dar un resultado
- **Newton:** Cuando se cumplieron condiciones iniciales favorables (puntos cercanos al óptimo, ej. $\mathbf{x}_0 = [0, 0]$), y se usaba la búsqueda lineal, este método demostró ser el más eficiente,

convergiendo al mínimo global en tan solo 5 a 9 iteraciones. Esto confirma la superioridad de la convergencia cuadrática cuando la función se comporta de manera adecuada en las proximidades del óptimo.




Figura 3: Gráfico de la mediana de iteraciones para convergencia al mínimo global(solo exitosos).

La Influencia Crítica de la Búsqueda de Línea:

La implementación de una estrategia de Búsqueda de Línea (Backtracking/Line Search) resultó ser un factor determinante para la convergencia:

- **Prevención de Mínimos Locales:** Tanto el GD como el Método de Newton, al no usar la búsqueda de línea, mostraron una alta propensión a converger hacia un mínimo local subóptimo ($f \approx 1,64...$) cuando las condiciones iniciales favorecían esta trayectoria. La búsqueda de línea fue esencial para garantizar que el paso de actualización fuera lo suficientemente grande para escapar de la atracción de los mínimos locales.
- **Ajuste Dinámico del Paso:** Para el Gradiente Descendente, el uso de Backtracking eliminó la dependencia de una tasa de aprendizaje (learning rate, lr) fija, resultando en una convergencia rápida y estable, incluso con $\mathbf{x}_0$ muy distantes.




Figura 4: Gráfico que muestra el rol crucial de la búsqueda lineal.

Casos más interesantes:

1. Método de Newton iniciando en (0,0) con Line Search activado: Es la convergencia más rápida de todas. Alcanza el mínimo global en menos de 10 iteraciones (usualmente 5-9). Demuestra el poder de la convergencia cuadrática de Newton cuando las condiciones son perfectas: cerca del mínimo y con una búsqueda de línea que lo protege.

2. Gradiente Descendente, iniciando muy lejos en (-100, -100), con Backtracking activado: A pesar de empezar lejos del objetivo, este experimento encuentra el mínimo global de forma limpia y rápida (en unas 14-20 iteraciones). Es el ejemplo perfecto de robustez: no importa el punto inicial, el backtracking ajusta el paso y llega a su destino eficientemente.

3. Método de Newton, iniciando lejos en (-100, -100), pero con Line Search: Demuestra que ni siquiera el Line Search puede salvar a Newton cuando está demasiado lejos. La curvatura de la función (el Hessiano) en ese punto es tan mala que el algoritmo se estanca, alcanzando las 200 iteraciones máximas sin haberse movido significativamente (la norma del gradiente sigue siendo altísima).

4. Método de Newton, iniciando lejos (100, -100), y sin Line Search: Esto es un desastre total. El algoritmo no solo falla, sino que diverge a valores infinitos (NaN) o absurdamente grandes. Es el mejor ejemplo de por qué Newton sin protección es una muy mala idea en funciones no cuadráticas.

5. Gradiente Descendente, iniciando en (50, 50) (cuadrante positivo), sin Backtracking: Este experimento converge perfectamente... al mínimo local incorrecto ($f \approx 1.64$). Como empezó en el valle equivocado y no tenía un mecanismo (backtracking) para ajustar su paso de forma inteligente, simplemente se fue por el camino más fácil y se quedó atascado allí.

6. Método de Newton, iniciando en (10, 10), sin Line Search: Similar al anterior, pero más sutil. Converge rapidísimo, pero al mínimo local. Es un "falso positivo": si solo miras la velocidad, parece un éxito, pero encontró la respuesta incorrecta.

7. Exactamente la misma que el ejemplo 5, pero esta vez con Backtracking activado: Este es el gemelo del ejemplo 5. Empezando en el mismo (50, 50), el backtracking le permite dar pasos más audaces y ajustados, logrando "saltar" la atracción del mínimo local y encontrar el camino hasta el mínimo global verdadero. Es la mejor prueba del poder del backtracking.

8. El gemelo del ejemplo 6. El Line Search detecta que el paso que lo llevaría al mínimo local no es óptimo y lo corrige, guiándolo hacia el mínimo global. Demuestra que el Line Search no solo previene la divergencia, sino que también corrige la dirección hacia un óptimo mejor.

9. Gradiente Descendente, iniciando lejos (-100, -100), sin Backtracking y con un learning rate (lr) bajo (0.01): Este experimento sí llega al mínimo global, pero le toma una eternidad (a menudo miles de iteraciones, acercándose al límite de 5000). Demuestra el problema de un lr fijo: si es demasiado pequeño para ser seguro, es terriblemente ineficiente.

10. Gradiente Descendente, iniciando lejos (-100, -100), sin Backtracking y con un lr alto (0.2): Es el opuesto al ejemplo 9. El lr es demasiado alto. El algoritmo probablemente divergió o rebotó erráticamente. Junto con el 9, demuestra por qué adivinar un lr fijo es una mala estrategia y por qué el backtracking (que lo hace dinámico) es la solución correcta.

5. Conclusiones:

En resumen, la comparación muestra que ambos métodos son capaces de encontrar mínimos locales, pero Newton es significativamente más rápido y eficiente cuando se encuentra en la vecindad de un mínimo. Newton tiene pasos más precisos y directos, muy pocas iteraciones cerca del mínimo, converge rápidamente y con gran estabilidad, pero el resultado final depende fuertemente del punto inicial, especialmente en regiones donde la función tiene múltiples mínimos. Mientras que GD tiene pasos pequeños, descenso gradual, sensible al paso inicial y al backtracking, puede requerir muchas iteraciones, pero encuentra consistentemente un mínimo local cercano al punto inicial. Ofrece un comportamiento más predecible y gradual desde cualquier punto inicial. El mínimo global alcanzado en la mayoría de los experimentos cercanos al origen corresponde aproximadamente a (-0.586506, -0.586506) con un valor final de la función aproximado a -0.6926.